



УДК 004.05:004.3-6
DOI <https://doi.org/10.38161/1996-3440-2024-4-75-98>

И. Г. Румановский, Н. А. Калинников

ПОВЫШЕНИЕ ТОЧНОСТИ ПРОГНОЗИРОВАНИЯ РАЗМЕРОВ КОРРОЗИОННЫХ ДЕФЕКТОВ ТРУБОПРОВОДОВ ПРИ ПРОВЕДЕНИИ МАГНИТНОЙ ДЕФЕКТОСКОПИИ ПОСРЕДСТВОМ СОВМЕСТНОГО ПРИМЕНЕНИЯ МЕТОДА КОНЕЧНЫХ ЭЛЕМЕНТОВ И НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ

Румановский И. Г. - канд. техн. наук, доцент Высшей школы управления природными ресурсами, ТОГУ, г. Хабаровск, 001776@pnu.edu.ru;

Калинников Н. А. – аспирант Высшей школы кибернетики и цифровых технологий, ТОГУ, г. Хабаровск, 012432@pnu.edu.ru

В предлагаемой статье представлен новый подход к диагностике технического состояния трубопроводов методом магнитоскопии (MFL), который сочетает моделирование методом конечных элементов с технологиями искусственных нейронных сетей. Во-первых, предложена физическая модель дефектного участка трубопровода на основе метода конечных элементов (МКЭ) для тестирования дефектов, обнаруживаемых MFL, обсуждается влияние состояний намагниченности на сигналы MFL и анализируется изменение экстремума сигнала в зависимости от интенсивности намагничивания. Затем выбираются подходящие характеристики сигнала MFL, чтобы установить связь между типами и размерами дефектов. Наконец, предложена прогностическая модель машины экстремального обучения ядра (KELM) для классификации типов дефектов и прогнозирования размеров дефектов. Результаты показывают, что по мере увеличения интенсивности намагничивания процесс намагничивания трубопровода можно разделить на нелинейную фазу роста и линейную фазу, при этом экстремум сигнала MFL быстро увеличивается, а затем постепенно растет линейно. Различные геометрические характеристики дефектов соответствуют различным распределениям сигналов MFL, эффективно отражая изменения типов и размеров дефектов. По сравнению с традиционными моделями ELM, модель KELM обеспечивает более высокую точность прогнозирования и стабильную производительность, при этом радиальная базисная функция ядра значительно расширяет возможности обобщения и прогнозирования нейронной сети.



Ключевые слова: тестирование утечки магнитного потока, конечно-элементное моделирование, искусственная нейронная сеть, извлечение признаков, машина экстремального обучения ядра (KELM).

Введение

Нефть и природный газ являются важнейшими источниками энергии и химическим сырьем, играя ключевую роль в промышленном производстве, экономическом развитии страны. Учитывая огнеопасную и взрывоопасную природу нефти и газа, крайне важно уделять первостепенное внимание безопасности при их транспортировке. Транспортировка по трубопроводам стала основным и широко используемым методом перемещения этих ресурсов благодаря своей высокой безопасности, высокой надежности и экономической эффективности [1]. Тем не менее, по мере увеличения срока службы трубопроводов увеличивается вероятность коррозии и утечек углеводородов. Для обеспечения непрерывной безопасной эксплуатации трубопроводов регулярные проверки и техническое обслуживание являются обязательными для предотвращения инцидентов, связанных с безопасностью. В настоящее время распространенные технологии неразрушающего контроля трубопроводов включают в себя MFL-тестирование, вихревой контроль [2-4] и ультразвуковой контроль [5-8]. Среди этих методов MFL-тестирование выделяется своими исключительными возможностями обнаружения, высокой степенью автоматизации и универсальностью применения. Эта технология предъявляет минимальные требования к среде инспекции и обеспечивает точное онлайн-обнаружение без связующих агентов. Данные, полученные в результате MFL-тестирования, могут эффективно определять повреждения трубопроводов. Обработка и анализ сигналов утечки не только помогают в обнаружении дефектов, но и облегчают идентификацию таких компонентов, как сварные швы, клапаны, тройники, фланцы и колена, тем самым помогая в локализации дефектов.

Технология MFL-тестирования [9] основана на высоких проникаемых свойствах ферромагнитных трубопроводов, стенки которых могут быть намагниченены до насыщения или почти до насыщения однородным магнитным полем, создаваемым с помощью постоянного магнита или катушки. В областях нормальной трубы линии магнитной индукции от приложенного магнитного поля ограничены внутренней частью стенки трубы, при этом линии магнитной индукции, выходящие из поверхности стенки трубы, минимальны или отсутствуют. Однако при наличии дефекта в стенке трубы проникаемость дефекта становится меньше, чем у нормальной области, что приводит к увеличению магнетосопротивления по сравнению с нормальной областью. Эта разница в свойствах приводит к утечке линий магнитной индукции либо сверху, либо снизу дефекта. Затем утечка магнитного потока может быть обнаружена датчиком эффекта Холла [10], как показано на рис. 1.

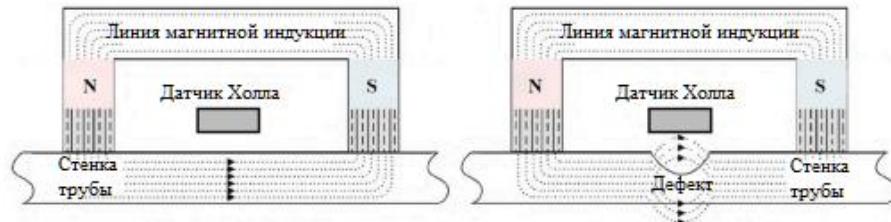


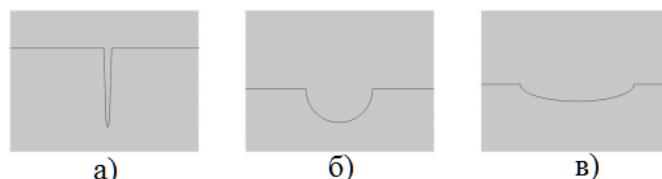
Рис. 1. Схематическая диаграмма испытания утечки магнитного потока

Традиционный метод обнаружения основан на ручной интерпретации кривой MFL, процессе, известном своей неэффективностью, субъективностью и восприимчивостью к ошибкам. С постоянным развитием технологий искусственного интеллекта были реализованы многочисленные подходы на основе ИИ в тестировании MFL для трубопроводов. Эти методы дали значительные улучшения в эффективности, обеспечивая при этом многообещающие результаты. В исследовании [11] извлекали четыре различных признака дефекта, а именно: заметность, контраст, центроид и отпечаток пальца. Затем они применили методы опорных векторов, случайного леса и К-ближайших соседей, чтобы различать нормальные и дефектные области на изображениях MFL. В исследовании [12] использовали анализ главных компонентов для объединения трех компонентов изображений MFL. По сравнению с использованием только одного компонента, объединенное изображение инкапсулирует расширенную информацию о форме дефекта, краях и четырех углах. Решая задачу точного обнаружения мелких целей, Янг и др. [13] ввели свертку полости и модуль остаточного внимания в алгоритм SSD. Это дополнение оказалось эффективным при обнаружении мелких целей, автоматически идентифицируя кольцевые сварные швы, спиральные сварные швы и дефекты. Вышеупомянутое исследование подчеркивает значительные достижения, достигнутые технологией искусственного интеллекта, в частности машинным обучением и глубоким обучением, в сферах распознавания образов, классификации изображений и обнаружения целей. Многие из этих достижений нашли практическое применение в области тестирования трубопроводов MFL. Однако существующие исследования часто упускают из виду состояние намагниченности, которое не может гарантировать, что трубопроводы намагниченены до насыщения перед тестированием MFL. Кроме того, искусственные нейронные сети в основном используются для идентификации типа дефекта, с ограниченным акцентом на прогнозировании регрессии и анализе размера дефекта. В свете этих соображений в данной статье исследуется метод обнаружения дефектов трубопровода, основанный на принципах MFL, посредством комбинации теоретического анализа, моделирования методом конечных элементов и искусственных нейронных сетей. Мы используем программное обеспечение COMSOL Multiphysics 6.0 для создания физической модели дефектного участка трубопровода на основе метода конечных элементов. Данная модель применялась для обнаружения дефектов трубопровода посредством применения метода неразрушающего контроля MFL. Сигналы обнаружения утечек количественно определяются, а характеристики сигнала выбираются и извлекаются для анализа закономерностей распределения сигналов утечек для различных

типов и размеров дефектов. Опираясь на эту основу, мы используем программное обеспечение MATLAB для разработки модели KELM для определения типов дефектов и прогнозирования размеров дефектов. Вышеупомянутая работа устанавливает теоретическую основу для неразрушающего контроля и обеспечения безопасности нефте- и газопроводов.

Численное моделирование для испытания утечки магнитного потока. Моделирование методом конечных элементов

Учитывая геометрические размеры и эффект намагничивания намагничающего устройства, для локализованного намагничивания дефектных трубопроводов был выбран метод ярма. Возбуждающая катушка, намотанная несколькими витками однородных проводов, по которым течет постоянный ток, используется для генерации стабильного магнитного поля без скин-эффекта [14]. Модель конечных элементов для испытания MFL создана с использованием COMSOL Multiphysics. Геометрическая модель включает в себя воздушную область, дефектные трубопроводы, возбуждающую катушку и ярмо магнита, как показано на рис. 2. Толщина стенки трубы составляет 19,1 мм, а длина трубы для моделирования методом конечных элементов установлена на уровне 2 м. Дефекты расположены в центре внешней стенки трубопроводов, дефект трещины, точечный дефект и дефект полосы показаны на рис. 2, а), б) и рис. 2, в) соответственно. Путь обнаружения сигнала расположен над стенкой трубы для замены элемента Холла, а высота подъема установлена на уровне 40 мм, как указано синей пунктирной линией на рис. 3.



*Рис. 2. Изображение дефектов во внешней стенке трубопровода:
а) трещины; б) точечный; в) полосовой*

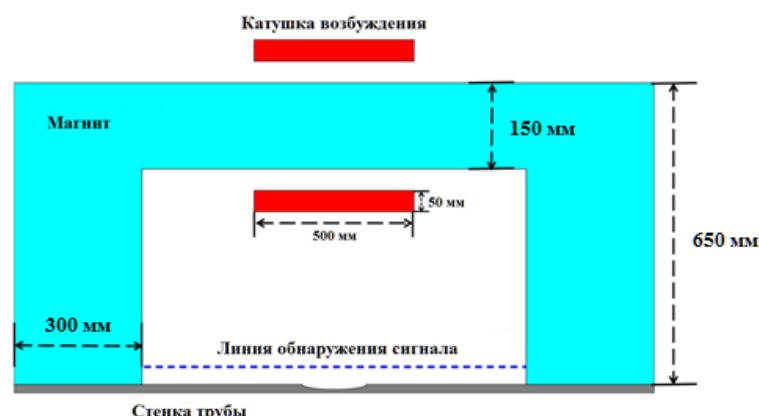


Рис. 3. Конечно-элементная модель испытания утечки магнитного потока



В численном моделировании высококачественная сетка не только экономит оперативную память, но и повышает точность расчетов. Чтобы обеспечить точность сигналов MFL, используется равномерная сетка с шагом 1 мм для разделения воздушной области вокруг области дефекта и пути обнаружения сигнала. Остальные области разделены с помощью свободной треугольной сетки. Общая сетка состоит из 298 158 ячеек сетки, причем самая большая ячейка имеет размер 30 мм, а самая маленькая — 0,06 мм. Самая большая ячейка демонстрирует скорость роста 1,1, а коэффициент кривизны установлен на уровне 0,2. Возбуждающая катушка изготовлена из меди с относительной проницаемостью 0,9999912. Ядро магнита изготовлено из мягкого железа без потерь в соответствии с библиотекой материалов COMSOL. Стенка трубы состоит из ферромагнитной трубопроводной стали X100, для учета нелинейного поведения материалов относительная проницаемость включена в кривую В-Н [15], которая изображена на рис. 4.

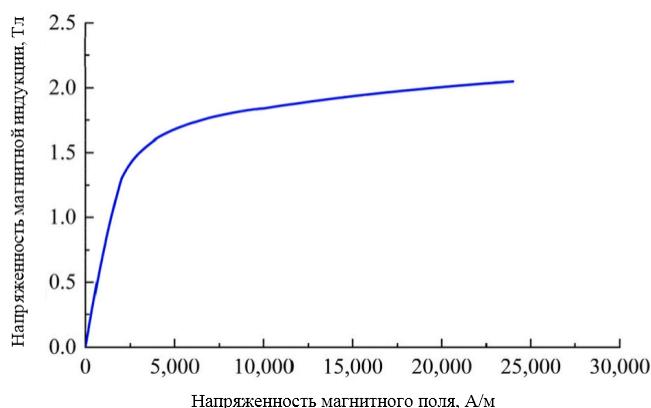


Рис. 4. Кривая В-Н трубопровода из стали X100

Анализ результатов моделирования

Стационарное исследование проведено с использованием модели конечных элементов с возбуждающей катушкой, намотанной на 3000 витков и генерирующей ток 30 А. Рис. 5 иллюстрирует распределение интенсивности магнитной индукции и линий магнитного потока в различных областях модели. По изменению цвета можно заметить, что интенсивность магнитной индукции в области трубы значительно выше, чем в других областях, при этом максимальная интенсивность находится в месте дефекта.

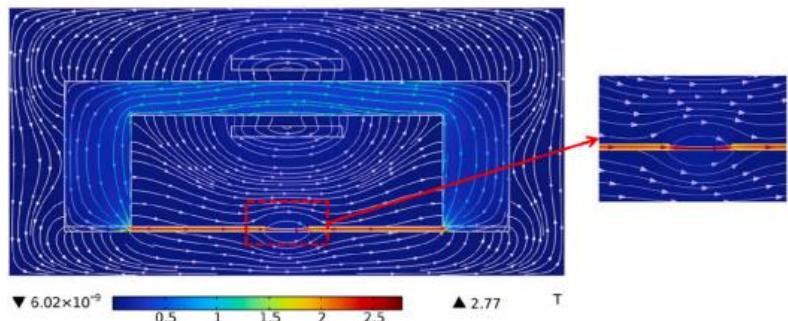


Рис. 5. Напряженность магнитной индукции и распределение линий магнитной индукции

Результаты моделирования показывают, что выбранный метод намагничивания постоянным током эффективно реализует процесс намагничивания. Наблюдение за линиями магнитного потока показывает, что линии магнитной индукции, генерируемые возбуждающей катушкой, передаются через ярмо во внутреннюю часть трубы. В месте дефекта некоторые линии магнитной индукции перетекают в воздушную область, тем самым образуя магнитное поле утечки.

Плотность магнитного потока вдоль пути обнаружения сигнала служит характерным параметром для сигнала MFL. Осевая и радиальная компоненты распределения сигнала MFL показаны на рис. 6. Осевая компонента показывает симметричное распределение и пики в центре дефекта. Радиальная компонента, напротив, демонстрирует симметричное распределение с пиками и впадинами на левой и правой сторонах дефекта соответственно.

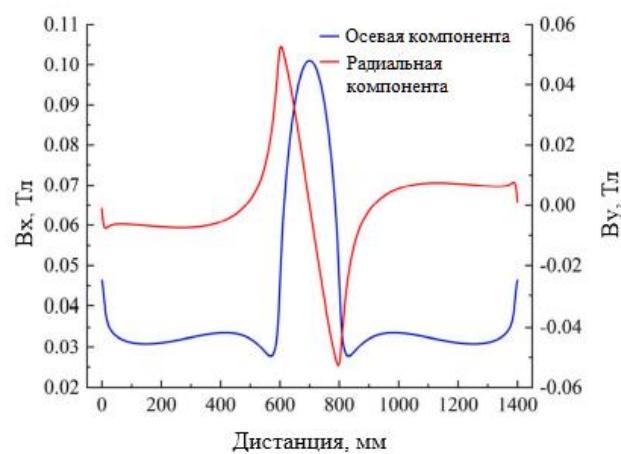


Рис. 6. Кривая распределения сигнала рассеяния магнитного потока



Влияние интенсивности намагничивания на сигнал утечки магнитного потока

При различных состояниях намагничивания материалы могут проявлять различные магнитные свойства. Соответствующая интенсивность намагничивания имеет решающее значение для обеспечения точности испытания MFL. Достижение насыщенного состояния намагничивания в трубопроводах может повысить точность сигналов MFL, облегчая последующий анализ и обработку этих сигналов.

Для изучения влияния состояний намагничивания на испытание MFL необходимо намагничивать трубопроводы до насыщения. Конечноэлементные модели для испытания MFL созданы для трубопроводов с трещинами, точечными дефектами и дефектами полос. Интенсивность намагничивания характеризуется текущим значением катушки возбуждения. Влияние состояния намагничивания на испытание MFL исследуется путем поддержания катушки возбуждения с 3000 витками постоянной и постепенного увеличения входного тока. Распределение сигналов MFL при различных интенсивностях тока показано на рис. 7. Можно заметить, что увеличение интенсивности намагничивания не изменяет форму кривой распределения сигнала MFL, но экстремум кривых как аксиальной, так и радиальной составляющей показывает значительные изменения.

Экстремумы кривых распределения сигнала MFL при различных значениях силы тока показаны на рис. 8. Очевидно, что как экстремумы осевой, так и радиальной составляющей непрерывно увеличиваются с ростом силы тока. Чтобы более наглядно описать изменение экстремумов магнитного сигнала утечки с интенсивностью намагничивания, вычисляется первая производная экстремумов по интенсивности тока для определения скорости роста экстремумов сигнала MFL. Анализ рис. 8 показывает, что для трубопроводов с различными типами дефектов изменения экстремумов сигнала MFL можно разделить на две отдельные стадии: стадия нелинейного роста и стадия линейного роста. На стадии нелинейного роста экстремумы сигнала MFL быстро увеличиваются с ростом силы тока. Скорость роста сначала быстро увеличивается до максимального значения, затем постепенно уменьшается и колеблется. На стадии линейного роста дальнейшее увеличение силы тока приводит к медленному линейному росту экстремумов сигнала MFL, при этом скорость роста минимальна и остается относительно постоянной.

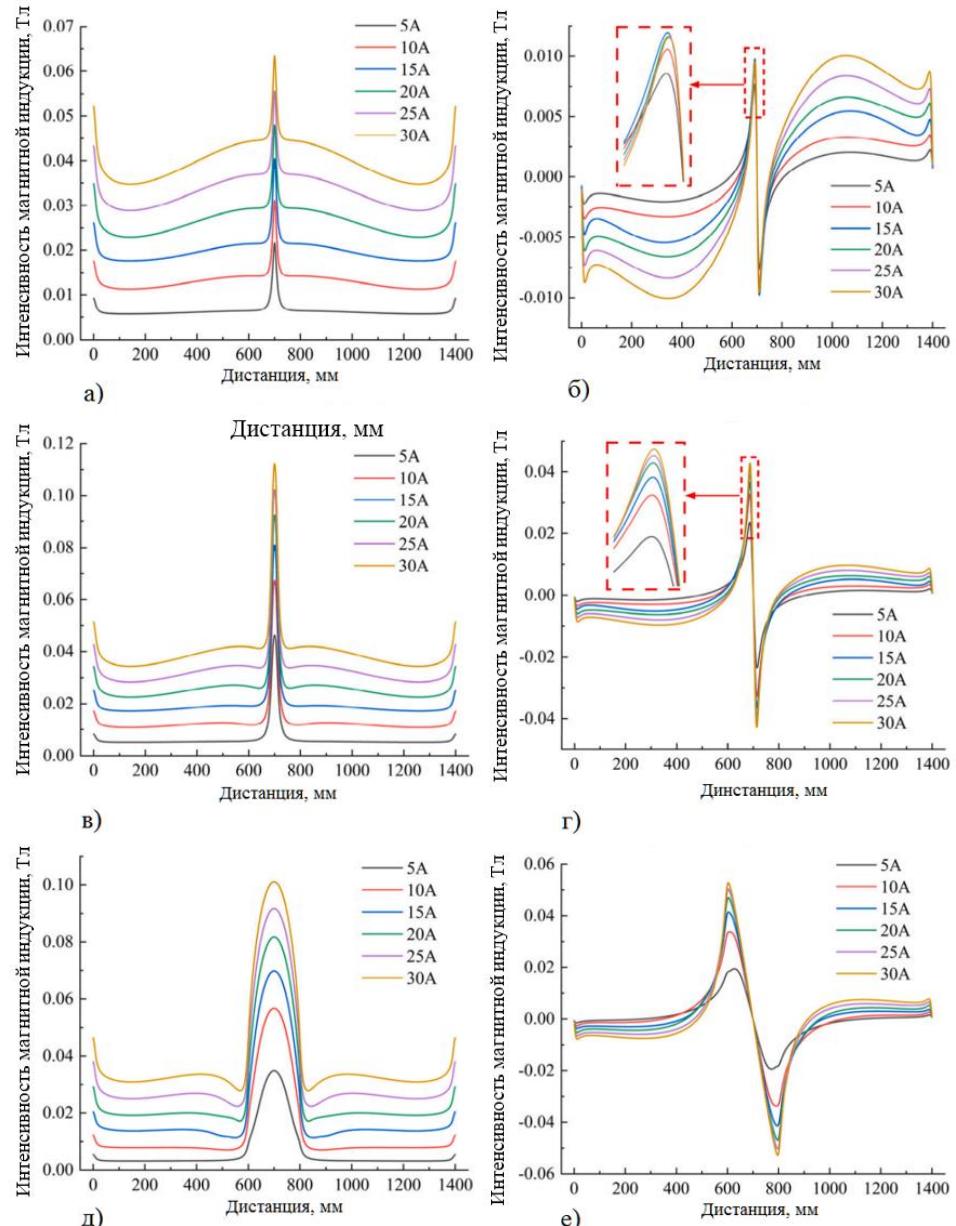


Рис. 7. Кривые распределения сигнала рассеяния магнитного потока при различной интенсивности тока:

- а) Осевого компонента дефекта трещины в трубопроводе;
- б) Радиального компонента дефекта трещины в трубопроводе;
- в) Осевого компонента точечного дефекта в трубопроводе;
- г) Радиального компонента точечного дефекта в трубопроводе;
- д) Осевого компонента полосового дефекта в трубопроводе;
- е) Радиального компонента полосового дефекта в трубопроводе

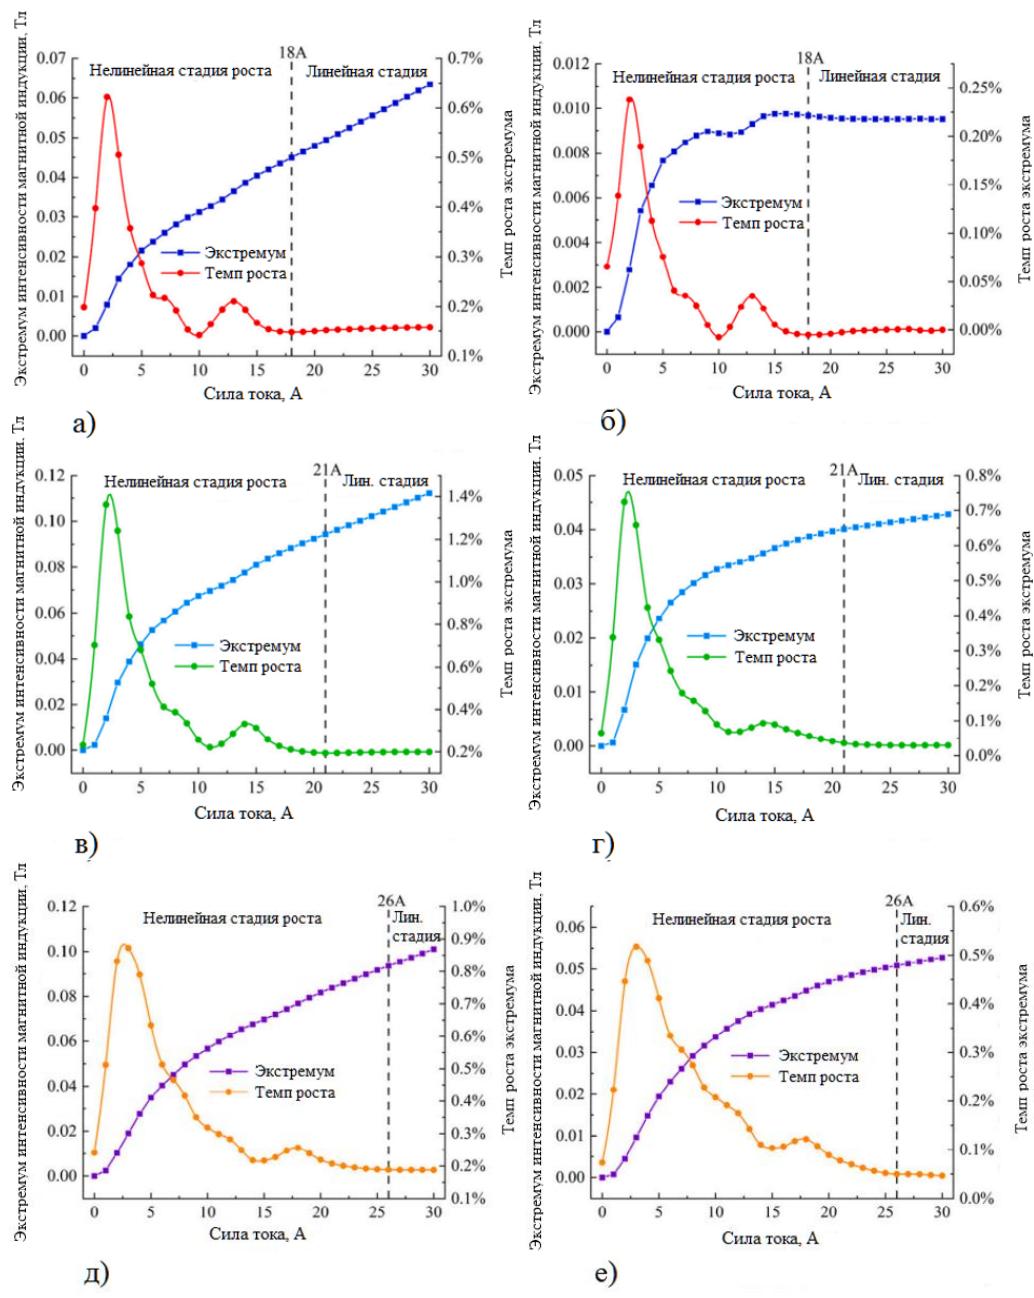


Рис. 8. Кривая изменения экстремума сигнала рассеяния магнитного потока:
а) Осевого компонента дефекта трещины в трубопроводе; б) Радиального компонента дефекта трещины в трубопроводе; в) Осевого компонента точечного дефекта в трубопроводе;
г) Радиального компонента точечного дефекта в трубопроводе; д) Осевого компонента полосового дефекта в трубопроводе; е) Радиального компонента полосового дефекта в трубопроводе

Когда сила тока достигает 18 А, 21 А и 26 А соответственно для трубопроводов с дефектами типа трещин, точечных дефектов и полосовых дефектов, экстремумы сигналов MFL входят в стадию линейного роста, при этом скорость роста стабилизируется. В этот момент можно предположить, что стенка трубы достигла состояния насыщенной намагниченности. Для повышения точности испытаний MFL и обеспечения намагничивания трубопроводов с различными типами дефектов до насыщения в этом исследовании используется катушка возбуждения, намотанная 3000 витками однородной проволоки, и подается постоянный ток 30 А для последующего анализа численного моделирования.

Анализ характеристик сигнала утечки магнитного потока

Изменения в типах и размерах дефектов тесно влияют на распределение сигнала MFL, и количественное исследование может точно выяснить связь между ними. В центре внимания количественного исследования находится тщательный выбор и извлечение характеристик сигнала. В соответствии с анализом кривых распределения сигналов MFL определения характеристик сигнала изложены следующим образом:

1. Как показано на рис. 9, сигнал аксиального компонента демонстрирует один пик и два провала, тогда как сигнал радиального компонента демонстрирует два пика и два провала. Базовая линия устанавливается вдоль нижнего края кривой аксиального компонента, а область, ограниченная кривой и базовой линией, обозначается как волновая область аксиального компонента (S_1). Аналогично, для радиального компонента базовая линия создается путем соединения двух впадин, а абсолютная область, ограниченная кривой и базовой линией, определяется как волновая область радиального компонента (S_2).
2. Разница между пиком и впадиной сигнала аксиальной составляющей обозначается как значение от пика до впадины (P_1). Одновременно разница между положительным пиком и отрицательным пиком сигнала радиальной составляющей определяется как значение от пика до пика (P_2).
3. Интервал между двумя впадинами сигнала аксиальной составляющей обозначается как расстояние от впадины до впадины (D_1). Кроме того, расстояние между положительным пиком и отрицательным пиком сигнала радиальной составляющей определяется как расстояние от пика до пика (D_2).

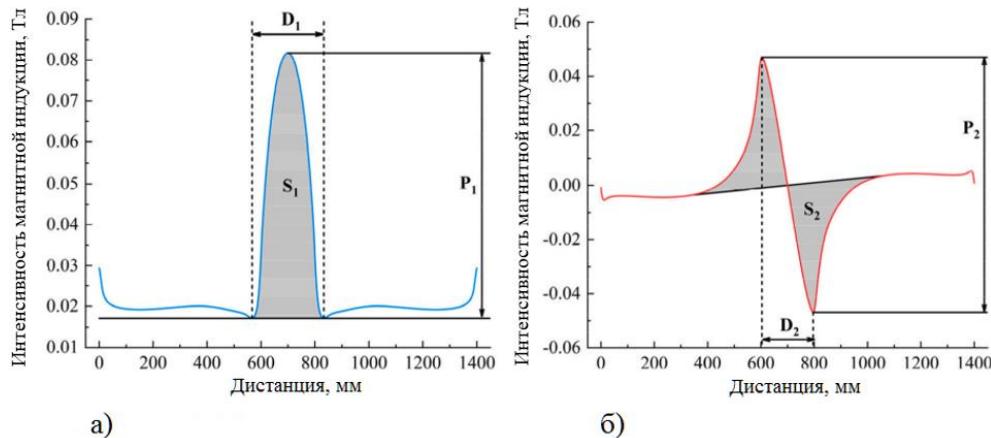


Рис. 9. Характеристики сигнала утечки магнитного потока:
а) Осевого компонента; б) Радиального компонента

Для исследования закономерностей распределения сигналов MFL при различных типах дефектов устанавливаются модели трубопроводов со следующими дефектами: дефект трещины глубиной 10 мм, точечный дефект радиусом 10 мм и полосовой дефект глубиной 10 мм и длиной 200 мм.

В табл. 1 представлены характеристики сигналов MFL для различных типов дефектов. При одинаковой глубине дефекта трубопровод с дефектом полосы демонстрирует наивысшее пиковое значение сигналов MFL, за ним следует трубопровод с точечным дефектом, а трубопровод с дефектом трещины демонстрирует наименьшее пиковое значение. Закрытая область и ширина сигналов MFL также следуют этой тенденции. Анализ показывает, что выбранные характеристики сигнала могут служить основой для классификации дефектов.

Таблица 1

Особенности сигнала утечки магнитного потока при различных типах дефектов

Тип дефекта	P_1	P_2	S_1	S_2	D_1	D_2
Дефект трещины	0,01888	0,01913	0,39337	0,42116	135	16
Точечный дефект	0,06417	0,07585	2,00754	3,00311	145	28
Полосовой дефект	0,06462	0,09396	10,24982	9,69446	266	195

На основе этого устанавливаются модели трубопровода с различными размерами дефектов. Модели изменения характеристик сигнала MFL для различных размеров дефектов показаны на рис. 10. Анализ показывает, что пиковое значение и закрытая область сигнала MFL демонстрируют линейную зависимость с увеличением глубины дефекта трещины, радиуса точечного

дефекта, глубины дефекта полосы и длины дефекта полосы. Однако ширина сигнала MFL показывает нерегулярные изменения.

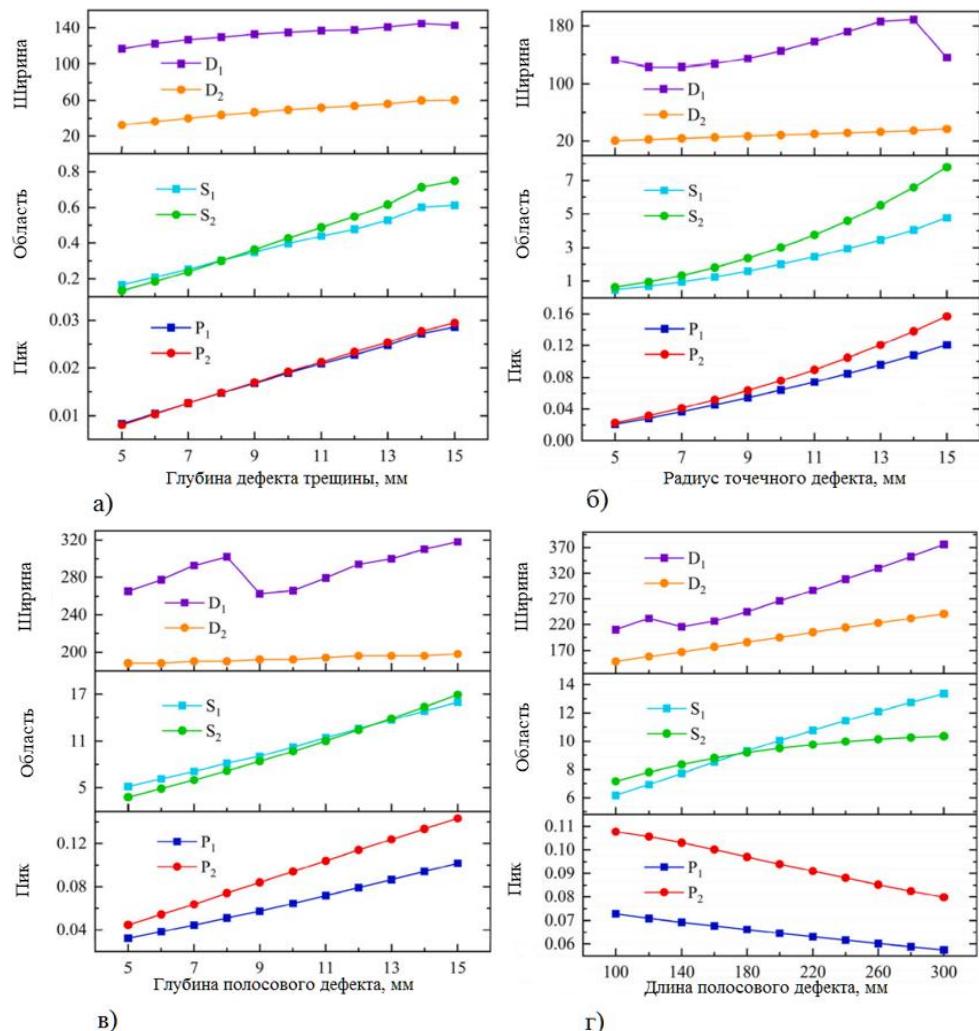


Рис. 10. Характеристики сигнала утечки магнитного потока для:

- Глубины дефекта трещины;
- Радиуса точечного дефекта;
- Глубины полосового дефекта;
- Длины полосового дефекта

Прогнозирование информации о дефектах. Модель прогнозирования по KELM

Extreme Learning Machine (ELM) – это алгоритм машинного обучения, основанный на однослойных скрытых нейронных сетях прямого распространения (SLFN), впервые предложенный Г. Б. Хуангом [15] в 2006



году. ELM имеет трехслойную сетевую структуру, похожую на SLFN, включающую входной слой, скрытый слой и выходной слой, как показано на рис. 11. В отличие от традиционных алгоритмов нейронных сетей, ELM не ищет оптимальное решение с помощью итеративного градиентного спуска. Вместо этого он случайным образом генерирует веса для входного слоя и смещения для скрытого слоя. Используя принцип псевдообратной матрицы Мура-Пенроуза, он применяет метод наименьших квадратов для решения линейных уравнений для весов выходного слоя. В процессе обучения не требуется никаких корректировок; нужно просто заранее установить количество нейронов скрытого слоя. По сравнению с обычными алгоритмами нейронных сетей, ELM имеет меньше параметров обучения, что эффективно позволяет избежать длительных итерационных процессов и значительно повышает скорость обучения. Кроме того, ELM демонстрирует сильные возможности обобщения и хорошо работает при обработке крупномасштабных, многомерных данных, что делает его пригодным для решения сложных задач.

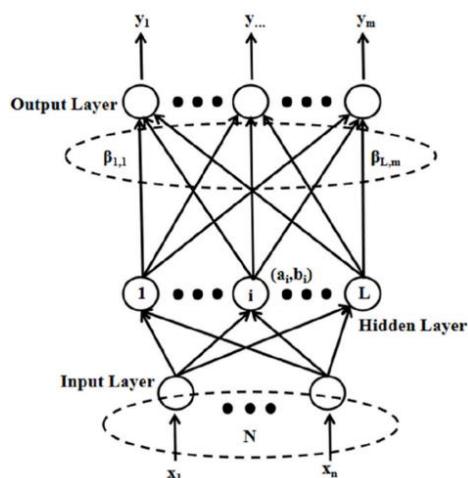


Рис. 11. Модель ELM

На рис. 11 входной слой содержит n нейронов, соответствующих n входным переменным; скрытый слой состоит из L нейронов; а выходной слой имеет m нейронов, соответствующих m выходным переменным. При наличии выборочного набора и функции активации скрытого слоя $g(x)$ ELM можно выразить как:

$$\sum_{i=1}^L \beta_{i,j} g(a_i \cdot x_j + b_i) = y_j \quad (1)$$

где $j = 1, 2, \dots, N$, N представляет собой количество образцов; a_i — веса входного слоя; и b_i обозначает смещения скрытого слоя. Уравнение (1) можно выразить в матричной форме как $Y = H \times \beta$, где Y представляет собой матрицу выходного слоя; H обозначает матрицу нейронов; а β — матрица выходного веса, выраженная следующим образом:

$$Y = [y_1, y_2, \dots, y_N]^T \quad (2)$$

$$H = \begin{bmatrix} g(a_1x_1 + b_1) & \dots & g(a_Lx_1 + b_L) \\ g(a_1x_2 + b_1) & \dots & g(a_Lx_2 + b_L) \\ \vdots & \ddots & \vdots \\ g(a_1x_N + b_1) & \dots & g(a_Lx_N + b_L) \end{bmatrix}_{N \times L} \quad (3)$$

$$\beta = [\beta_1, \beta_2, \dots, \beta_N]^T \quad (4)$$

Для получения весов выходного слоя вычисляется псевдообратная матрица Мура-Пенроуза для H , что приводит к следующему выражению для весов выходного слоя:

$$\beta = H^T (HH^T)^{-1} Y \quad (5)$$

Для улучшения обобщающей способности модели вводятся коэффициент регуляризации C и единичная матрица I . Регуляризованное решение наименьших квадратов для β можно получить, решив следующее уравнение:

$$\beta = H^T \left(\frac{I}{C} + HH^T \right)^{-1} Y \quad (6)$$

На основании вышеприведенного вывода выходную функцию ELM можно выразить следующим образом:

$$y(x) = g(x) \cdot \beta = g(x) \cdot H^T \left(\frac{I}{C} + HH^T \right)^{-1} Y \quad (7)$$

В 2010 году Г. Б. Хуан [16] и его коллеги обнаружили, что функции ядра дают значительные преимущества при обработке больших объемов сложных данных. Интегрируя теоретические основы нелинейных опорных векторных машин, они ввели алгоритм Kernel Based Extreme Learning Machine (KELM) в ELM. Когда функция отображения признаков неизвестна, KELM устраняет необходимость случайного определения количества скрытых узлов слоя. Вместо этого он использует отображение ядра, что позволяет получать решение для весов выходного слоя исключительно через внутренний продукт функции ядра. Введение функций ядра позволяет ELM решать более сложные



нелинейные задачи, сохраняя при этом сильные возможности обобщения, повышая стабильность алгоритма и снижая вычислительную сложность. В алгоритме KELM матрица ядра представлена следующим образом:

$$\Omega_{\text{ELM}}(i, j) = g(x_i)g(x_j) = K(x_i, x_j) \quad (8)$$

где x_i, x_j представляет входные переменные, а $K(x_i, x_j)$ — функция ядра. Подстановка функции ядра в уравнение (7) дает:

$$y(x) = [K(x, x_1); \dots; K(x, x_N)] \left(\frac{I}{C} + HH^T \right)^{-1} Y \quad (9)$$

Использование программного обеспечения MATLAB для программирования модели прогнозирования KELM. Процесс начинается с импорта и предварительной обработки данных выборки. Этапы предварительной обработки включают идентификацию входных и выходных данных, разделение данных на обучающие и тестовые наборы и нормализацию данных. Затем определяются коэффициент регуляризации и параметры функции ядра в соответствии с характеристиками образца. Затем модель KELM обучается на основе этих параметров для получения выходной функции. Наконец, в соответствии с требованиями данные классифицируются, результаты выводятся и вычисляются точность и ошибка. Рабочий процесс изображен на рис. 12.

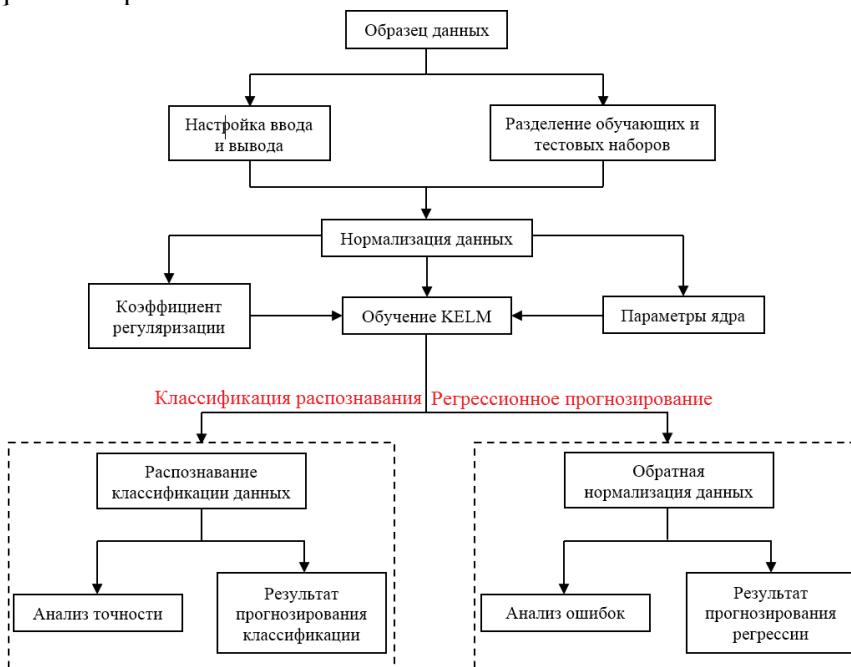


Рис. 12. Рабочий процесс KELM

Применение конечно-элементной модели для MFL-тестирования различных типов дефектов в трубопроводах. Для дефекта трещины диапазон глубины устанавливается от 5 мм до 15 мм, рассчитывается каждые 0,2 мм, что дает в общей сложности 51 сигнал MFL. Радиус точечных дефектов также устанавливается от 5 мм до 15 мм, рассчитывается каждые 0,2 мм, что дает еще 51 набор сигналов MFL. Для дефектов полосы диапазон глубины устанавливается от 5 мм до 15 мм, рассчитывается каждый мм, в то время как диапазон длины составляет от 100 мм до 300 мм, рассчитывается каждые 20 мм, что дает в общей сложности 121 сигнал MFL. Кривые сигнала MFL обрабатываются с помощью программного обеспечения Origin для извлечения характеристик сигнала, тем самым создавая выборочный набор данных для прогностической модели. Характеристики сигналов MFL для дефекта трещины, точечного дефекта и дефекта полосы представлены в табл. 2-4 соответственно.

Таблица 2
Характеристики сигнала утечки магнитного потока в дефектах трещины
трубопроводов

№	Глубина дефекта	P ₁	S ₁	D ₁	P ₂	S ₂	D ₂
1	5	0,00835	0,16619	116,9	0,00841	0,13128	15
2	5,2	0,00877	0,17468	117,6	0,00852	0,14038	15
...
25	9,8	0,01848	0,38456	134,2	0,01871	0,40484	16
26	10	0,01888	0,39337	134,9	0,01913	0,42116	16
...
50	14,8	0,02827	0,60509	142,6	0,02908	0,72776	17
51	15	0,02864	0,61358	142,9	0,02948	0,73864	17

Таблица 3
Характеристики сигнала утечки магнитного потока в точечных дефектах
трубопроводов

№	Глубина дефекта	P ₁	S ₁	D ₁	P ₂	S ₂	D ₂
1	5	0,02099	0,47867	132,7	0,02275	0,62054	20
2	5,2	0,02241	0,51646	128,2	0,02441	0,67844	20,1
...
25	9,8	0,06222	1,91999	142,5	0,07329	2,87468	27,9
26	10	0,06417	2,00754	144,7	0,07585	3,01331	28
...
50	14,8	0,11798	4,60695	135,1	0,15287	7,53274	35,9
51	15	0,12073	4,77175	135,3	0,15664	7,78816	36



Таблица 4
Характеристики сигнала утечки магнитного потока в полосовых дефектах
трубопроводов

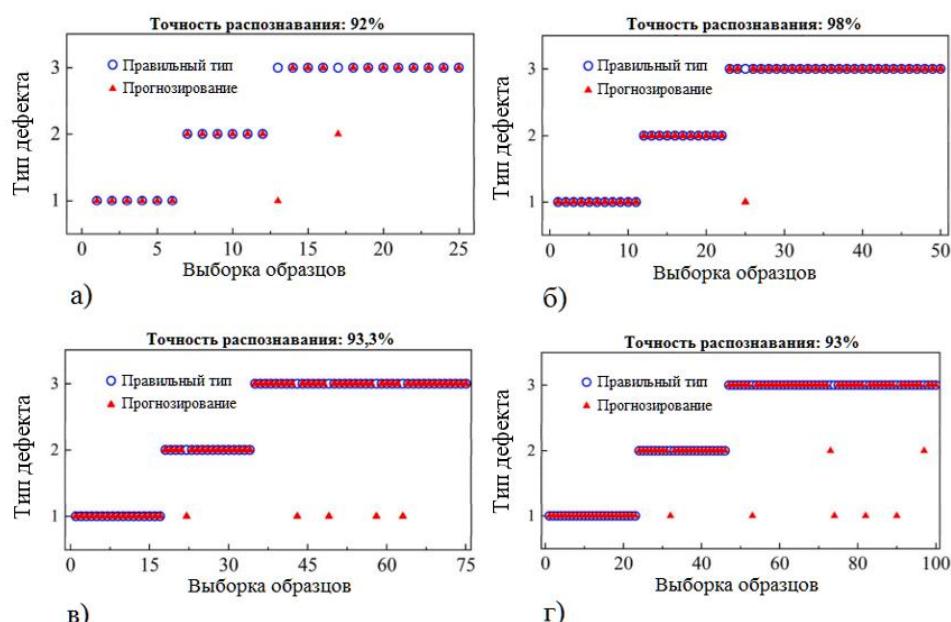
№	Глубина дефекта	Длина дефекта	P ₁	S ₁	D ₁	P ₂	S ₂	D ₂
1	5	100	0,0346	2,9029	168,7	0,0497	2,8426	94
<i>Продолжение табл. 4</i>								
2	5	120	0,03437	3,38905	187,3	0,04931	3,11886	114
...
60	10	180	0,06617	9,50429	245,3	0,09702	9,37892	186
61	10	200	0,06462	10,2498	266	0,09396	9,69446	195
...
120	15	280	0,08965	19,2552	398	0,12236	18,2842	276
121	15	300	0,08704	19,9627	400,7	0,11803	18,5620	294

Распознавание типа дефекта

В области машинного обучения соотношение деления между обучающим и тестовым наборами сильно влияет на прогностическую эффективность модели. Как правило, большая доля обучающего набора помогает модели лучше изучать закономерности данных, но доля тестового набора также должна быть достаточно большой, чтобы обеспечить точную оценку производительности обобщения модели. Чтобы определить оптимальное соотношение между обучающим и тестовым наборами, максимизируя возможности классификации и распознавания модели KELM, в качестве выборочного набора данных используются в общей сложности 223 набора признаков сигнала MFL из табл. 2–4. Метка категории «дефект трещины» установлена на 1, «точечный дефект» установлена на 2, а «дефект полосы» установлена на 3. Каждый набор данных содержал 7 признаков, причем S₁, P₁, D₁, S₂, P₂ и D₂ были входными переменными, а метка категории дефекта — выходной переменной. Набор данных выборки случайным образом перемешивается, и 25, 50, 75 и 100 наборов выбираются в качестве тестового набора, а оставшиеся наборы используются в качестве обучающего набора. Результаты классификации и распознавания модели KELM при различных размерах тестового набора показаны на рис. 13.

В машинном обучении важно выбирать признаки, соответствующие исследовательской задаче, в качестве входных переменных, в то время как выходная переменная представляет собой цель прогнозирования модели. Чтобы оценить классификационную и распознавательную способность модели KELM с различными входными признаками было сделано следующее. Во-первых, не изменяя настройки других параметров, количество входных

признаков сокращается с 6 до 3. В частности, признаки аксиального компонента S_1 , P_1 и D_1 , а также признаки радиального компонента S_2 , P_2 и D_2 по отдельности используются в качестве входных переменных для обучения модели KELM. Когда признаки аксиального компонента используются в качестве входных переменных, точность классификации модели KELM составляет 88 %, что на 10 % меньше по сравнению с использованием всех признаков сигнала. Ошибки классификации возникали несколько раз для «дефекта в виде трещины», «точечного дефекта» и «дефекта в виде полосы», вероятно, из-за небольших числовых различий в пиковых значениях и ширине осевого компонента сигналов MFL. Когда характеристики радиального компонента используются в качестве входных переменных, модель KELM достигает точности классификации 94 %, что немного ниже, чем при использовании всех характеристик сигнала. Каждая из категорий дефекта в виде трещины, точечного дефекта и дефекта в виде полосы испытала одну ошибку классификации, что указывает на достаточную способность распознавания классификации по сравнению с характеристиками осевого компонента.



Rис. 13. Результаты распознавания KELM с различными количествами тестовых наборов:

а) выборка из 25; б) выборка из 50; в) выборка из 75; г) выборка из 100



Эффективность прогнозирования модели KELM остается на высоком уровне при различном количестве тестовых наборов, при этом точность классификации постоянно превышает 90 %. Классификация «дефекта в виде трещины» полностью верна, а ошибки классификации в основном сосредоточены в «точечном дефекте» и «дефекте полосы». Когда количество тестовых наборов достигает 50 групп, модель KELM достигает наивысшей точности классификации, и только одна группа показывает ошибку классификации. Поэтому в последующих исследованиях в качестве тестового набора будут использоваться 50 случайно выбранных групп выборки.

Прогнозирование размера дефекта

Чтобы определить соответствующее соотношение обучающего и тестового наборов и максимизировать возможности регрессионного прогнозирования модели KELM, в качестве входных образцов используется 121 набор данных из табл. 4. Каждый набор данных содержит 8 признаков, причем S_1 , P_1 , D_1 , S_2 , P_2 и D_2 служат входными переменными. Глубина и длина дефектов полосы используются в качестве выходных переменных. Точность регрессионного прогнозирования модели проиллюстрирована на рис. 14.

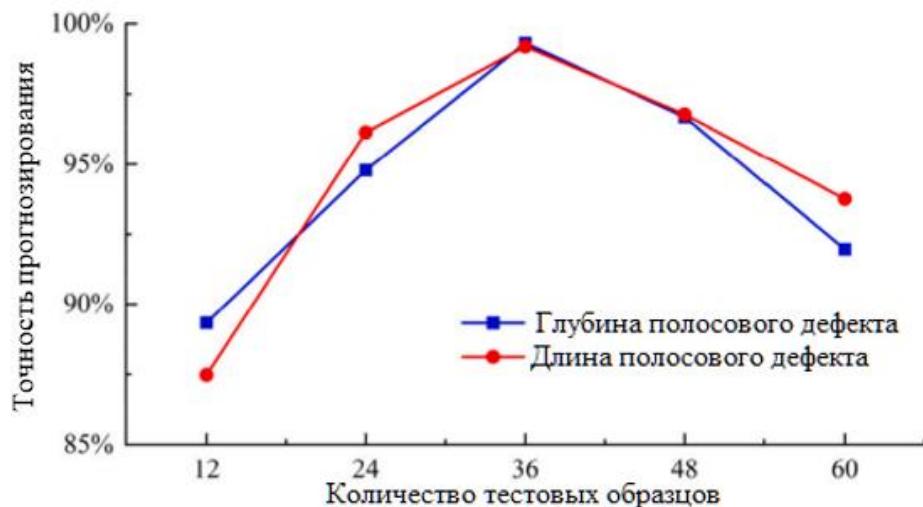


Рис. 14. Точность прогнозирования регрессии KELM с различными количествами тестовых образцов

Как избыточное, так и недостаточное количество тестовых образцов может отрицательно повлиять на прогностическую способность модели KELM. По мере увеличения количества тестовых образцов точность

прогнозирования сначала растет, а затем постепенно снижается. Поворотный момент наступает при 36 тестовых образцах, где точность прогнозирования достигает своего пика. Поэтому, когда соотношение обучающего и тестового наборов установлено на уровне 7:3, прогностическая эффективность установленной модели KELM максимизируется. Следовательно, это соотношение будет принято для разделения обучающего и тестового наборов в последующих исследованиях.

Подводя итог, можно сказать, что, используя как признаки осевого, так и радиального компонента в качестве входных данных и устанавливая выходные переменные как глубину дефекта трещины, радиус точечного дефекта, глубину дефекта полосы и длину дефекта полосы, набор данных разделяется на обучающий и тестовый наборы в соотношении 7:3. После случайного перемешивания и нормализации данных в табл. 2–4 используются как традиционная модель ELM, так и модель KELM. Результаты сравнения двух моделей в прогнозировании размеров дефектов показаны на рис. 15.

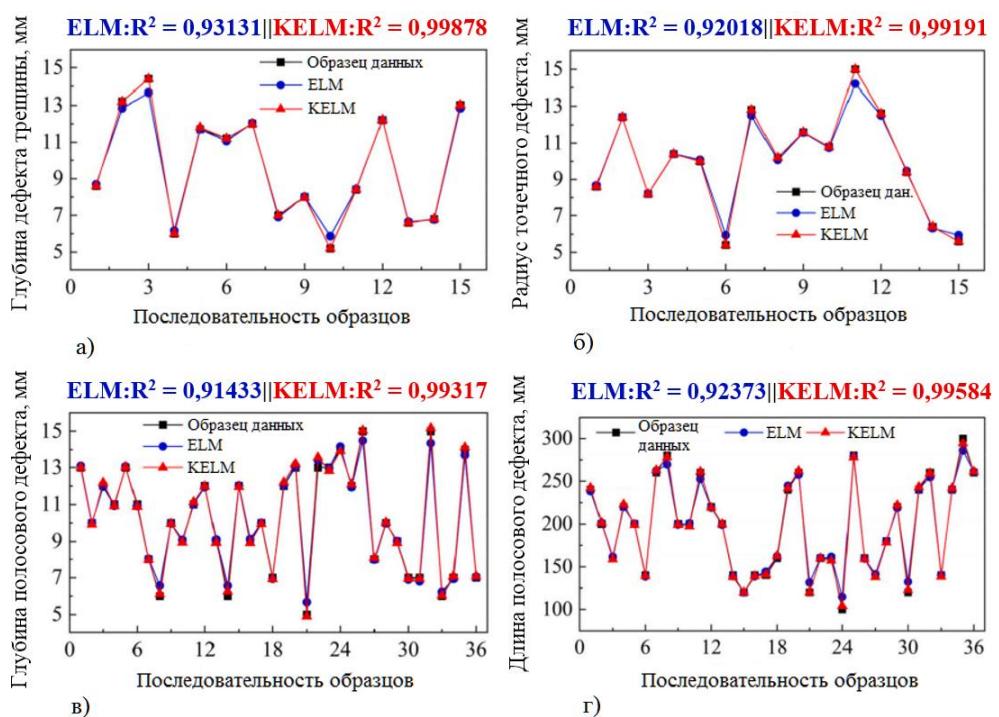


Рис. 15. Сравнение результатов регрессионного прогнозирования для ELM и KELM:
а) для глубины дефекта трещины; б) для радиуса точечного дефекта;
в) для глубины полосового дефекта; г) для длины полосового дефекта



Модель KELM достигает точности прогнозирования 99,878 %, 99,878 %, 99,317 % и 99,584 % для глубины дефекта трещины, радиуса точечного дефекта, глубины дефекта стержня и длины дефекта стержня соответственно, что близко соответствует данным выборки. По сравнению с традиционной моделью ELM точность улучшены на 6,747 %, 7,713 %, 7,884 % и 7,211 % соответственно, таким образом, модель KELM может точно прогнозировать изменения размеров различных типов дефектов. Использование функции ядра RBF значительно повышает производительность регрессионной модели, что приводит к более стабильным и выраженным улучшениям точности по сравнению с моделью ELM. Кроме того, удовлетворительная производительность прогнозирования подтверждает обоснованность и точность разделения обучающего/тестового набора и конфигурации входных и выходных переменных.

Заключение

Предложенное исследование посвящено проблеме мониторинга дефектных нефте- и газопроводов, и используется комбинация моделирования методом конечных элементов и искусственных нейронных сетей для исследования утечки магнитного потока. Была построена имитационная модель для изучения факторов, влияющих на сигналы MFL, и их закономерностей преобразования. В результате исследования предложен усовершенствованный алгоритм машинного обучения для прогнозирования информации о дефектах трубопроводов. Последующие выводы можно представить следующим образом:

1) По мере увеличения интенсивности намагничивания изменение сигналов MFL можно разделить на нелинейную фазу роста и линейную фазу. Во время нелинейной фазы роста экстремум сигналов MFL значительно увеличивается, причем скорость роста сначала быстро растет, а затем постепенно снижается. После входа в линейную фазу экстремум сигналов MFL увеличивается медленно и линейно, поддерживая относительно постоянную скорость роста, поскольку стенка трубы достигает состояния насыщения намагниченности.

2) Между тем, при той же глубине дефекта характеристики сигнала MFL дефектов полосы являются самыми высокими, за ними следуют точечные дефекты, а дефекты трещин демонстрируют самые низкие значения. Различные геометрические характеристики дефектов соответствуют различным распределениям сигналов MFL. Характеристики этих сигналов MFL эффективно отражают изменения как типов, так и размеров дефектов.

3) Модель KELM демонстрирует оптимальную производительность прогнозирования классификации, когда набор тестов включает 50 групп,

достигая точности 98 %. Когда обучающий и тестовый наборы разделены в соотношении 7:3, модель демонстрирует наилучшую производительность регрессионного прогнозирования, при этом показатели точности для прогнозирования глубины дефекта трещины, радиуса точечного дефекта, глубины дефекта полосы и длины дефекта полосы достигают 99,878 %, 99,191 %, 99,317 % и 99,584 % соответственно. Выбор характеристик магнитного сигнала утечки является как разумным, так и осуществимым, поскольку модель сохраняет высокую предсказательную способность даже после сокращения входных признаков. По сравнению с традиционными моделями экстремальных обучающихся машин (ELM) модель KELM демонстрирует стабильную производительность прогнозирования, последовательно достигая более высоких показателей точности как в распознавании вида дефекта, так и в прогнозировании скорости его роста.

Библиографический список:

1. Amr H., Amr E. Numerical sensitivity analysis of corroded pipes and burst pressure prediction using finite element modeling // Int. J. Pres. Ves. Pip., 2023. P. 202.
2. Mridul G., Ahmad M. K., Ravi B. Advances in applications of non-destructive testing (ndt) : a review // Advances in Materials and Processing Technologies 8(2). 2022. P. 2286-2307.
3. Sharatchandra W. S., Anish K. Effect of flaw orientation on magnetic flux leakage and remote field eddy current inspection of small diameter steel tubes // Nondestr. Test. Eval. 38(4). 2022. P. 553-571.
4. Eddy current testing methods and design for pipeline inspection system: a review / A. M. Joraijee, A. Kharudin, R. Damhuji, et al. // J. Phys. Conf. 2467(1). 2023.
5. Defect detection in pipes using Van der Pol systems based on ultrasonic guided wave / J. Wu, F. Yang, L. Jing, et al. // Int. J. Pres. Ves. Pip. 195. 2022.
6. Non-invasive ultrasonic inspection of sludge accumulation in a pipe / C. Piao, S. H. Kim, J. K. Lee, et al. Ultrasonics 119. 2022.
7. Towlson A. R. K., Croxford A. J., Drinkwater B. W. Ultrasonic non-destructive characterisation of blockages and defects in underground pipes // IEEE Trans. Ultrason. Ferroelectrics Freq. Control. 69(8). 2022. P. 2540-2554.
8. Ultrasonic guided wave techniques and applications in pipeline defect detection: a review / X. L. Zang, Z. D. Xu, H. F. Lu, et al. // Int. J. Pres. Ves. Pip. 206 . 2023.



9. A novel MFL detection method based on low frequency AC magnetization for identification defect / S. X. Zhang, J. Feng, S. X. Lu, et al. // J. Magn. Magn Mater. 580. 2023.

10. Denk F., Hofbauer T. Determination of the magnetic intermediate permeability of special materials based on FEM-simulation and Hall-sensor measurement // Magnetism 3(2). 2023. P. 169-179.

11. Window feature-based two-stage defect identification using magnetic flux leakage measurements / J. H. Liu, M. R. Fu, F. L. Liu, et al. // IEEE Trans. Instrum. Meas. 67(1). 2018. P. 12-23.

12. Modeling and experimental studies on 3D-magnetic flux leakage testing for enhanced flaw detection in carbon steel plates / Kumar S., Mukhopadhyay, et al. // Res. Nondestr. Eval. 30(5). 2019. P. 253-268.

13. Yang L. J., Wang Z. J., Gao S. W. Pipeline magnetic flux leakage image detection algorithm based on multiscale SSD network // IEEE Trans. Ind. Inf. 16(1). 2020. P. 501-509.

14. The unit integral calculation method of defective material's forward question of magnetic flux leakage detection based on the magnetic dipole model / Y. S. Li, Q. Z. Liu, J. Liu, et al. // Trans. China Electrotech. Soc. 32(21). 2017. P. 176-185.

15. Huang G., Zhu Q., Siew C. Extreme learning machine: theory and applications // Neurocomputing 70(1). 2005. P. 489-501.

16. Huang G., Ding X., Zhou H. Optimization method based extreme learning machine for classification // Neurocomputing 74(1). 2010. P. 155-163.

17. Li Y., Sun C. Research on magnetic flux leakage testing of pipelines by finite element simulation combined with artificial neural network. China.: Int. J. Pres. Ves. Pip 212, 2024.

Title: Improving the Accuracy of Predicting the Size of Corrosion Defects in Pipelines during Magnetic Flaw Detection through the Combined Use of the Finite Element Method and Neural Network Technologies

Authors' affiliation:

Rumanovskiy I. G. – Pacific National University, Khabarovsk, Russian Federation
Kalinikov N. A. – Pacific National University, Khabarovsk, Russian Federation



Abstract: In this article, a new approach to pipeline fault condition diagnosis by magnetoscopy (MFL) is presented, which combines finite element modeling with artificial neural network technologies. Firstly, a physical model of the defective pipeline section based on the finite element method (FEM) is proposed to test the defects detected by MFL, the influence of magnetization states on the MFL signals is discussed, and the change of the signal extremum with respect to the magnetization intensity is analyzed. Then, suitable characteristics of the MFL signal are selected to establish the relationship between the defect types and sizes. Finally, a kernel extreme learning machine (KELM) predictive model is proposed to classify the defect types and predict the defect sizes. The results show that as the magnetization intensity increases, the pipeline magnetization process can be divided into a nonlinear growing phase and a linear phase, with the MFL signal extremum increasing rapidly and then gradually increasing linearly. Different geometric characteristics of the defects correspond to different distributions of the MFL signals, effectively reflecting the changes in the defect types and sizes. Compared with traditional ELM models, KELM model achieves higher prediction accuracy and stable performance, and the radial basis function of the kernel greatly enhances the generalization and prediction capability of the neural network.

Keywords: magnetic flux leakage testing, finite element modeling, artificial neural network, feature extraction, kernel extreme learning machine (KELM).